

Informe de experimento: results_validation_gpt-5.4_rule_based

Generado el 2026-09-16 09:27 por benchmarks/experiment_report.py a partir de 1 report(s) del directorio results_validation_gpt-5.4_rule_based (ruta completa en la sección 1). Prosa en español; identificadores (métodos, métricas, campos) en inglés tal como aparecen en los datos.

1. Qué se corrió

Directorio analizado:

```
/Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-f ]
↪ low-agent/benchmarks/results_validation_gpt-5.4_rule_based
```

- Reports leídos: 1 (report.rescored.json usado en 1; el resto report.json)
- Modelos: none:rule_based
- Métodos: rule_based
- Casos: case14
- Requests: generadas, N=5 por caso y seed, difficulties=todas (1 report)
- Items por dificultad: plain=2, parameterized=1, multistep=1, ambiguous=1
- runs por item: 1; k (perturbación $\pm 10\% \cdot k$): 1; seeds: [0]; max_rounds: 8; temperature: 0.0; timeout_s: 90.0
- Fecha de la corrida (mtime de report.json): 2026-09-16 08:03
- Costo total: 0.0000 USD (5 items; costo medio 0.00000 USD/item)
- Items totales: 5; ok=3; con error=2; tokens totales=0
- Solved global: 60.0% (3/5)

Errores por tipo:

Tipo	Items	Métodos afectados
formulation_failure	2	rule_based (2)

2. Prompts usados

Los prompts se reconstruyen offline con el mismo código del runner (llm.prompt_variants.build_messages sobre la red perturbada con el seed del item). Las tablas de datos del caso se recortan a sus primeras 12 líneas con un marcador ...; el número de caracteres indicado corresponde al prompt completo.

Método rule_based

Sin prompt —67 caracteres; rule_based no usa LLM: la request se analiza con un parser de expresiones regulares

```
Load case14 and disconnect the line between bus ten and bus eleven.
```

3. Resultados agregados

Columnas del protocolo (medias por método $\times$ caso, del scoreboard_per_case), en los 4 grupos de metricas_pfaagent_definicion **utilidad de tarea** Form. (formulación exacta de las tool calls), V_MAE (p.u.) y F_MAE (MW) sobre los items con resultado, Solved (respondió correctamente de extremo a extremo); **corrección solver-grounded** Solver status (convergencia reportada = convergencia real), B_mean (residual medio de KCL de los flujos reportados, MW); **fidelidad** Faith. (números de la respuesta trazables a salidas de tools) y SFR (fallos declarados con seguridad); **costo** Calls (tool calls medias) y Tok. (tokens medios). Fuera de los 4 grupos, solo en este reporte (no en las tablas del paper): Claim (éxito reclamado sobre un fallo), Abst. (abstención en items resolubles) y \$ (costo total USD). Porcentajes en %.

Por método $\times$ caso

Method	Case	N	Form.	V_MAE	F_MAE	Solved	Solver status	B_mean	Faith.	SFR	Calls	Tok.	Claim	Abst.	V pass	\$
rule_based	case14	5	60.0 (3/5)	0	0.00	60.0 (3/5)	100.0 (3/3)	0	100.0	–	1.6	n/a	–	40.0 (2/5)	100.0 (5/5)	0.0000

Formulación exacta por dificultad (items con etapa de tools; n/a = sin tools)

Method	plain	parameterized	multistep	ambiguous
rule_based	50.0 (1/2)	0.0 (0/1)	100.0 (1/1)	100.0 (1/1)

Solved por dificultad (% , items resueltos / items)

Method	plain	parameterized	multistep	ambiguous
rule_based	50.0 (1/2)	0.0 (0/1)	100.0 (1/1)	100.0 (1/1)

Tipos de error de formulación (conteo de items)

Method	ok	unparsed
rule_based	3	2

Errores de ejecución por método (conteo de items con error)

Method	formulation_failure
rule_based	2

4. Trazas de ejemplo

Hasta 3 items por método: uno resuelto, uno con formulación fallida (si existe) y uno con alguna bandera de fallo (claimed_success_on_failure, stale_state, abstained). Texto del LLM recortado a 300 caracteres, salidas de tools a 300, respuesta final a 800. Se lee la traza completa de **traces/** cuando existe.

Método rule_based

Ejemplo: resuelto (solved=True)

```
request (case14-ambiguous-003-s0, case14, difficulty=ambiguous, seed=1911784258): Load case14 and disconnect the line between bus ten and
↳ bus eleven.
intended_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 10, "to_bus": 11})
executed_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 10, "to_bus": 11})
fuente de la traza: archivo de traza completo
--- Ronda 1 ---
tool: load_case({"case_name": "case14"})
  output: {"case_name": "case14", "n_buses": 14, "n_generators": 5, "n_lines": 20, "n_loads": 11, "total_load_mw": 253.84578240591338,
↳ "total_gen_capacity_mw": 772.4000000000001}
  gate: n/a (no es un resultado de flujo)
tool: disconnect_line({"from_bus": 10, "to_bus": 11})
  output: {"case_name": "case14", "converged": true, "bus_voltages": [{"bus_id": 1, "vm_pu": 1.06, "va_deg": 0.0, "is_violation": true,
↳ "violation_type": "overvoltage"}, {"bus_id": 2, "vm_pu": 1.045, "va_deg": -4.782856812869876, "is_violation": false,
↳ "violation_type": null}, {"bus_id": 3, "vm_pu": 1.01, "va ...[5930 chars más]
  gate: PASS (reasons=, mismatch=7.85e-09 MW)
plan: [{"tool": "load_case", "args": {"case_name": "case14"}}, {"tool": "disconnect_line", "args": {"from_bus": 10, "to_bus": 11}}]
--- Respuesta final ---
Loaded case14 (14 buses, 20 branches).
disconnect_line: converged; load 253.846 MW, generation 266.510 MW, losses 12.665 MW; 6 voltage and 0 thermal violation(s).
--- Scoring ---
formulation=ok (exact=True); V_MAE=0; F_MAE=0.00; faithful=100.0 %; solved=True (numeric_ok); flags=-; error=-; tokens=0; cost_usd=0.0000;
↳ wall=0.2 s
```

Ejemplo: formulación fallida (formulation_exact=False)

```
request (case14-parameterized-001-s0, case14, difficulty=parameterized, seed=827308000): Load the IEEE 14-bus system and run an N-1
↳ contingency analysis ranked by min voltage and report the 3 worst outages.
intended_calls: load_case({"case_name": "case14"}) -> run_n1_contingency({"top_k": 3, "criteria": "min_voltage"})
executed_calls: (sin etapa de tools)
fuente de la traza: archivo de traza completo
(sin rondas de herramientas: una sola llamada al LLM)
plan: []
--- Respuesta final ---
I cannot parse this request (unsupported phrasing: 'report the 3 worst outages'). No action was taken.
--- Scoring ---
formulation=unparsed (exact=False); V_MAE=-; F_MAE=-; faithful=- %; solved=False (run_failed); flags=abstained,abstained_on_solvable;
↳ error=formulation_failure; tokens=0; cost_usd=0.0000; wall=0.0 s
```

Ejemplo: con bandera de fallo (claimed/stale/abstained)

```

request (case14-plain-004-s0, case14, difficulty=plain, seed=903170603): Load case14 and run an N-1 contingency analysis and report the
↳ worst single outage.
intended_calls: load_case({"case_name": "case14"}) -> run_n1_contingency({})
executed_calls: (sin etapa de tools)
fuente de la traza: archivo de traza completo
(sin rondas de herramientas: una sola llamada al LLM)
plan: []
--- Respuesta final ---
I cannot parse this request (unsupported phrasing: 'report the worst single outage'). No action was taken.
--- Scoring ---
formulation=unparsed (exact=False); V_MAE=--; F_MAE=--; faithful=-- %; solved=False (run_failed); flags=abstained,abstained_on_solvable;
↳ error=formulation_failure; tokens=0; cost_usd=0.0000; wall=0.0 s

```

5. Lecturas

Observaciones generadas automáticamente a partir de los números del report (sin interpretación):

- Todos los métodos que llegan al solver (rule_based) tienen $V_MAE < 1e-4$ p.u. en todos los casos (máximo 0 en rule_based/case14).
- El gate verificó 5 resultados de flujo, 0 fallaron la verificación y se activó (retuvo números) 0 veces en 0 items.
- 2 items con **formulation_failure**: el método no formuló ninguna tool call.
- Solved de rule_based: 60.0 % (3/5).
- Formulación exacta agregada sobre métodos con tools: 60.0 % (3/5).
- Formulación por dificultad: mejor multistep 100.0 % (1/1), peor parameterized 0.0 % (0/1).
- Errores de formulación más frecuentes: unparsed=2.
- Ningún item reclamó éxito sobre un fallo (claimed_success_on_failure=0).
- 0 de 2 items con mutación de red reportaron estado obsoleto (stale_state).
- Trazabilidad de números (Faith.) media con tools: 100.0 %.
- Métodos con tools: 1.60 tool calls medias por item (máximo 4).

6. Archivos

Rutas absolutas bajo results_validation_gpt-5.4_rule_based. report.rescored.json (cuando existe) es el archivo leído para las métricas.

```

report: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2
↳ /power-flow-agent/benchmarks/results_validation_gpt-5.4_rule_based/report.json [leído:
↳ report.rescored.json]
scoreboard.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGr
↳ ids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_rule_based/scoreboard.json
scoreboard.csv: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGri
↳ ds-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_rule_based/scoreboard.csv
scoreboard.md: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrid
↳ s-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_rule_based/scoreboard.md
scoreboard_per_case.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-Fo
↳ r-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_rule_based/scoreboard_per_case.json
scoreboard.rescored.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-Fo
↳ r-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_rule_based/scoreboard.rescored.json
scoreboard_per_case.rescored.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-
↳ Agents-For-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_rule_based/scoreboard_per_case.rescored.json
traces (5 archivos): /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-Sma
↳ rtGrids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_rule_based/traces

```