

Informe de experimento: results_validation_gpt-5.4_stress_rule_based

Generado el 2026-09-16 13:21 por benchmarks/experiment_report.py a partir de 1 report(s) del directorio results_validation_gpt-5.4_stress_rule_based (ruta completa en la sección 1). Prosa en español; identificadores (métodos, métricas, campos) en inglés tal como aparecen en los datos.

1. Qué se corrió

Directorio analizado:

```
/Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-f ]
↪ low-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based
```

- Reports leídos: 1 (report.rescored.json usado en 1; el resto report.json)
- Modelos: none:rule_based
- Métodos: rule_based
- Casos: case14
- Requests: generadas, N=5 por caso y seed, difficulties=['stress'] (1 report)
- Items por dificultad: stress=10
- runs por item: 1; k (perturbación $\pm 10\% \cdot k$): 1; seeds: [0, 1]; max_rounds: 8; temperature: 0.0; timeout_s: 90.0
- Fecha de la corrida (mtime de report.json): 2026-09-16 13:21
- Costo total: 0.0000 USD (10 items; costo medio 0.00000 USD/item)
- Items totales: 10; ok=6; con error=4; tokens totales=0
- Solved global: 0.0 % (0/10)

Errores por tipo:

Tipo	Items	Métodos afectados
formulation_failure	4	rule_based (4)

2. Prompts usados

Los prompts se reconstruyen offline con el mismo código del runner (llm.prompt_variants.build_messages sobre la red perturbada con el seed del item). Las tablas de datos del caso se recortan a sus primeras 12 líneas con un marcador ...; el número de caracteres indicado corresponde al prompt completo.

Método rule_based

Sin prompt –90 caracteres; rule_based no usa LLM: la request se analiza con un parser de expresiones regulares

```
Load the IEEE 14-bus system and disconnect the transformer branch between bus 7 and bus 8.
```

3. Resultados agregados

Columnas del protocolo (medias por método $\times$ caso, del scoreboard_per_case), en los 4 grupos de metricas_pfactagent_definicion **utilidad de tarea** Form. (formulación exacta de las tool calls), V_MAE (p.u.) y F_MAE (MW) sobre los items con resultado, Solved (respondió correctamente de extremo a extremo); **corrección solver-grounded** Solver status (convergencia reportada = convergencia real), B_mean (residual medio de KCL de los flujos reportados, MW); **fidelidad** Faith. (números de la respuesta trazables a salidas de tools) y SFR (fallos declarados con seguridad); **costo** Calls (tool calls medias) y Tok. (tokens medios). Fuera de los 4 grupos, solo en este reporte (no en las tablas del paper): Claim (éxito reclamado sobre un fallo), Abst. (abstención en items resolubles) y \$ (costo total USD). Porcentajes en %.

Por método $\times$ caso

Method	Case	N	Form.	V_MAE	F_MAE	Solved	Solver status	B_mean	Faith.	SFR	Calls	Tok.	Claim	Abst.	pass	\$
rule_based	case14	10	50.0 (5/10)	–	0.00	0.0 (0/10)	83.3 (5/6)	0	100.0	40.0 (4/10)	1.7	n/a	60.0 (6/10)	–	–	0.0000

Formulación exacta por dificultad (items con etapa de tools; n/a = sin tools)

Method	stress
rule_based	50.0 (5/10)

Solved por dificultad (%, items resueltos / items)

Method	stress
rule_based	0.0 (0/10)

Tipos de error de formulación (conteo de items)

Method	missed_step	ok	unparsed
rule_based	1	5	4

Errores de ejecución por método (conteo de items con error)

Method	formulation_failure
rule_based	4

4. Trazas de ejemplo

Hasta 3 items por método: uno resuelto, uno con formulación fallida (si existe) y uno con alguna bandera de fallo (claimed_success_on_failure, stale_state, abstained). Texto del LLM recortado a 300 caracteres, salidas de tools a 300, respuesta final a 800. Se lee la traza completa de **traces/** cuando existe.

Método rule_based

Ejemplo: formulación fallida (formulation_exact=False)

```
request (case14-stress-001-s1, case14, difficulty=stress, seed=1222356006): Load the 14-bus test case (case14), increase the load at bus 3
↳ to 565.2 MW and 114 Mvar (six times its nominal value), increase the active load at bus 4 to 286.8 MW (six times its nominal value),
↳ and finally increase the load at bus 9 to 177 MW and 99.6 Mvar (six times its nominal value).
intended_calls: load_case({"case_name": "case14"}) -> modify_load({"bus_id": 3, "p_mw": 565.2, "q_mvar": 114.0}) -> modify_load({"bus_id":
↳ 4, "p_mw": 286.8}) -> modify_load({"bus_id": 9, "p_mw": 177.0, "q_mvar": 99.6})
executed_calls: (sin etapa de tools)
fuente de la traza: archivo de traza completo
(sin rondas de herramientas: una sola llamada al LLM)
plan: []
--- Respuesta final ---
I cannot parse this request (unsupported phrasing: 'increase the load at bus 3 to 565.2 MW and 114 Mvar (six times its nominal value)'). No
↳ action was taken.
--- Scoring ---
formulation=unparsed (exact=False); V_MAE=--; F_MAE=--; faithful=100.0 %; solved=False (run_failed); flags=-; error=formulation_failure;
↳ tokens=0; cost_usd=0.0000; wall=0.0 s
```

Ejemplo: con bandera de fallo (claimed/stale/abstained)

```
request (case14-stress-000-s0, case14, difficulty=stress, seed=1813382119): Load the IEEE 14-bus system and disconnect the transformer
↳ branch between bus 7 and bus 8.
intended_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 7, "to_bus": 8})
executed_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 7, "to_bus": 8})
fuente de la traza: archivo de traza completo
--- Ronda 1 ---
tool: load_case({"case_name": "case14"})
output: {"case_name": "case14", "n_buses": 14, "n_generators": 5, "n_lines": 20, "n_loads": 11, "total_load_mw": 252.6562386075145,
↳ "total_gen_capacity_mw": 772.4000000000001}
gate: n/a (no es un resultado de flujo)
tool: disconnect_line({"from_bus": 7, "to_bus": 8})
output: {"case_name": "case14", "converged": true, "bus_voltages": [{"bus_id": 1, "vm_pu": 1.06, "va_deg": 0.0, "is_violation": true,
↳ "violation_type": "overvoltage"}, {"bus_id": 2, "vm_pu": 1.045, "va_deg": -4.898954247812662, "is_violation": false,
↳ "violation_type": null}, {"bus_id": 3, "vm_pu": 1.01, "va_deg": 5624 chars más}
gate: FAIL (reasons=isolated_or_unsolved_buses, mismatch=9.78e-09 MW)
plan: [{"tool": "load_case", "args": {"case_name": "case14"}}, {"tool": "disconnect_line", "args": {"from_bus": 7, "to_bus": 8}}]
--- Respuesta final ---
Loaded case14 (14 buses, 20 branches).
disconnect_line: converged; load 252.656 MW, generation 265.463 MW, losses 12.807 MW; 4 voltage and 0 thermal violation(s).
--- Scoring ---
formulation=ok (exact=True); V_MAE=--; F_MAE=0.00; faithful=100.0 %; solved=False (failure_not_declared); flags=claimed_success_on_failure;
↳ error=-; tokens=0; cost_usd=0.0000; wall=0.2 s
```

Ejemplo: no resuelto

```

request (case14-stress-000-s1, case14, difficulty=stress, seed=288545019): Load the IEEE 14-bus system and disconnect the transformer
↳ branch between bus 7 and bus 8.
intended_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 7, "to_bus": 8})
executed_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 7, "to_bus": 8})
fuente de la traza: archivo de traza completo
--- Ronda 1 ---
tool: load_case({"case_name": "case14"})
  output: {"case_name": "case14", "n_buses": 14, "n_generators": 5, "n_lines": 20, "n_loads": 11, "total_load_mw": 256.29258445637254,
    ↳ "total_gen_capacity_mw": 772.4000000000001}
  gate: n/a (no es un resultado de flujo)
tool: disconnect_line({"from_bus": 7, "to_bus": 8})
  output: {"case_name": "case14", "converged": true, "bus_voltages": [{"bus_id": 1, "vm_pu": 1.06, "va_deg": 0.0, "is_violation": true,
    ↳ "violation_type": "overvoltage"}, {"bus_id": 2, "vm_pu": 1.045, "va_deg": -4.805283121873044, "is_violation": false,
    ↳ "violation_type": null}, {"bus_id": 3, "vm_pu": 1.0100000 ...[5530 chars más]
  gate: FAIL (reasons=isolated_or_unsolved_buses, mismatch=1.2e-08 MW)
plan: [{"tool": "load_case", "args": {"case_name": "case14"}}, {"tool": "disconnect_line", "args": {"from_bus": 7, "to_bus": 8}}]
--- Respuesta final ---
Loaded case14 (14 buses, 20 branches).
disconnect_line: converged; load 256.293 MW, generation 269.238 MW, losses 12.946 MW; 3 voltage and 0 thermal violation(s).
--- Scoring ---
formulation=ok (exact=True); V_MAE=--; F_MAE=0.00; faithful=100.0 %; solved=False (failure_not_declared); flags=claimed_success_on_failure;
↳ error=--; tokens=0; cost_usd=0.0000; wall=0.3 s

```

5. Lecturas

Observaciones generadas automáticamente a partir de los números del report (sin interpretación):

- El gate verificó 11 resultados de flujo, 7 fallaron la verificación y se activó (retuvo números) 0 veces en 0 items.
- 4 items con **formulation_failure**: el método no formuló ninguna tool call.
- Solved de **rule_based**: 0.0 % (0/10).
- Formulación exacta agregada sobre métodos con tools: 50.0 % (5/10).
- Errores de formulación más frecuentes: **unparsed=4, missed_step=1**.
- 6 items reclamaron éxito sobre un fallo (**claimed_success_on_failure**): **rule_based=6**.
- De 10 items en estado de fallo, 4 lo declararon de forma segura (SFR 40.0 % (4/10)).
- 0 de 6 items con mutación de red reportaron estado obsoleto (**stale_state**).
- Trazabilidad de números (Faith.) media con tools: 100.0 %.
- 10 items esperaban un resultado no convergido (**islanded=5, non_converged=5**); el método lo declaró correctamente (**solved**) en 0.0 % (0/10).
- Métodos con tools: 1.70 tool calls medias por item (máximo 4).

6. Archivos

Rutas absolutas bajo **results_validation_gpt-5.4_stress_rule_based**. **report.rescored.json** (cuando existe) es el archivo leído para las métricas.

```

report: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2
↳ /power-flow-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based/report.json [leído:
↳ report.rescored.json]
scoreboard.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGr
↳ ids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based/scoreboard.json
scoreboard.csv: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGri
↳ ds-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based/scoreboard.csv
scoreboard.md: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrid
↳ s-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based/scoreboard.md
scoreboard_per_case.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-Fo
↳ r-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based/scoreboard_per_case.json
scoreboard_rescored.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-Fo
↳ r-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based/scoreboard.rescored.json
scoreboard_per_case.rescored.json:
↳ /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/p
↳ ower-flow-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based/scoreboard_per_case.rescored.json
traces (10 archivos): /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-Sm
↳ artGrids-Code-v2/power-flow-agent/benchmarks/results_validation_gpt-5.4_stress_rule_based/traces

```