

Informe de experimento: react_nogate

Generado el 2026-09-17 23:56 por benchmarks/experiment_report.py a partir de 1 report(s) del directorio react_nogate (ruta completa en la sección 1). Prosa en español; identificadores (métodos, métricas, campos) en inglés tal como aparecen en los datos.

1. Qué se corrió

Directorio analizado:

```
/Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-f ]  
↪ low-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate
```

- Reports leídos: 1 (report.rescored.json usado en 1; el resto report.json)
- Modelos: openrouter:openai/gpt-5.4
- Métodos: react_nogate
- Casos: case14
- Requests: generadas, N=40 por caso y seed, difficulties=todas (1 report)
- Items por dificultad: plain=10, parameterized=10, multistep=10, ambiguous=10
- runs por item: 1; k (perturbación $\pm 10\% \cdot k$): 1; seeds: [0]; max_rounds: 8; temperature: 0.0; timeout_s: 90.0
- Fecha de la corrida (mtime de report.json): 2026-09-16 13:31
- Costo total: 1.3219 USD (40 items; costo medio 0.03305 USD/item)
- Items totales: 40; ok=40; con error=0; tokens totales=458729
- Solved global: 62.5% (25/40)

Errores por tipo:

(ningún item con error)

2. Prompts usados

Los prompts se reconstruyen offline con el mismo código del runner (llm.prompt_variants.build_messages sobre la red perturbada con el seed del item). Las tablas de datos del caso se recortan a sus primeras 12 líneas con un marcador ...; el número de caracteres indicado corresponde al prompt completo.

Método react_nogate

System prompt (SYSTEM_PROMPT_EN) —1557 caracteres; architecture=react, gate=False, memory=False

You are a power system power-flow analysis assistant. You help the user complete power system analysis tasks from natural-language requests.

```
## What you can do  
You complete tasks by calling tool functions:  
1. Load an IEEE standard test system (14, 30, 57, 118, 300 buses)  
2. Run AC power flow  
3. Modify the load at a bus and re-solve  
4. Disconnect or reconnect a line and re-solve  
5. Query the network status  
6. Run an N-1 contingency analysis (disconnect branches one at a time and rank the worst cases)  
7. Generate remedial-action suggestions (what-if load shedding or voltage adjustment) to reduce violation risk  
  
## Key rules  
- Never fabricate any numerical result. Every voltage, power, loss, or loading value must come from a tool return value.  
- If a tool reports an error or a non-converged power flow, say so explicitly and do not report numbers for that state.  
- If the request is ambiguous, state the interpretation you are using.  
- Bus and line identifiers in the request are MATPOWER 1-based ids; pass them to the tools as given, unless the request itself states a  
  ↪ different indexing convention for that identifier (e.g. "(0-based)"), in which case convert it to the MATPOWER 1-based id before  
  ↪ calling any tool.  
- After a network modification, re-solve before reporting any value.  
- Always reply in English.  
  
## Reply format  
After each analysis, reply in this structure:  
1. One-sentence summary  
2. Key numbers (total load, total generation, total losses, voltage range) taken from the tool outputs  
3. Violations, if any  
4. Suggested next step
```

User prompt (primer item) = request_text —67 caracteres; case=case14, seed=1911784258, k=1, request_id=case14-ambiguous-003-s0

Load case14 and disconnect the line between bus ten and bus eleven.

3. Resultados agregados

Columnas del protocolo (medias por método $\times$ caso, del `scoreboard_per_case`), en los 4 grupos de `metricas_pfactagent_definicion` **utilidad de tarea** Form. (formulación exacta de las tool calls), V_MAE (p.u., solo sobre peticiones con formulación exacta –toda fila con herramientas que llega al solver con la formulación correcta da exactamente cero, ver benchmarks/scoring.py) y F_MAE (MW) sobre los items con resultado, Solved (respondió correctamente de extremo a extremo); **corrección solver-grounded** Solver status (convergencia reportada = convergencia real), B_mean (residual medio de KCL de los flujos reportados, MW); **fidelidad** Faith. (por respuesta, no por número: fracción de respuestas donde todo número es trazable a una salida de tool Y viene del solve posterior al último cambio de red) y SFR (fallos declarados con seguridad); **costo** Calls (tool calls medias) y Tok. (tokens medios). Fuera de los 4 grupos, solo en este reporte (no en las tablas del paper): Claim (éxito reclamado sobre un fallo), Escalated y Wrong (silent) (con Solved, las tres suman 100 %: dónde termina cada petición –resuelta sola, entregada a una persona, o mal contestada sin aviso; solo cuenta como Escalated una arquitectura con mecanismo de traspaso real, ver benchmarks.scoring.escalation_check) y \$ (costo total USD). Porcentajes en %.

Por método $\times$ caso

Method	Case	N	Form.	V_MAE	F_MAE	Solved	Solver status	B_mean	Faith.	SFR	Calls	Tok.	Claim	Escalated	Wrong (silent)	\$
react_nogate	case14	440	62.5 (25/40)	0	0.01	62.5 (25/40)	100.0 (40/40)	0	90.0 (36/40)	–	2.8	11468–	0.0 (0/40)	37.5 (15/40)		1.3219

Formulación exacta por dificultad (items con etapa de tools; n/a = sin tools)

Method	plain	parameterized	multistep	ambiguous
react_nogate	80.0 (8/10)	90.0 (9/10)	40.0 (4/10)	40.0 (4/10)

Solved por dificultad (% , items resueltos / items)

Method	plain	parameterized	multistep	ambiguous
react_nogate	80.0 (8/10)	90.0 (9/10)	40.0 (4/10)	40.0 (4/10)

Tipos de error de formulación (conteo de items)

Method	extra_arg	changes_result	ok
react_nogate	15		25

Errores de ejecución por método (conteo de items con error)

(ningún item con error)

4. Trazas de ejemplo

Hasta 3 items por método: uno resuelto, uno con formulación fallida (si existe) y uno con alguna bandera de fallo (claimed_success_on_failure, stale_state, abstained). Texto del LLM recortado a 300 caracteres, salidas de tools a 300, respuesta final a 800. Se lee la traza completa de `traces/` cuando existe.

Método react_nogate

Ejemplo: resuelto (solved=True)

```
request (case14-ambiguous-003-s0, case14, difficulty=ambiguous, seed=1911784258): Load case14 and disconnect the line between bus ten and
↳ bus eleven.
intended_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 10, "to_bus": 11})
executed_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 10, "to_bus": 11})
fuente de la traza: archivo de traza completo
--- Ronda 1 ---
tool: load_case({"case_name": "case14"})
  output: {"case_name": "case14", "n_buses": 14, "n_generators": 5, "n_lines": 20, "n_loads": 11, "total_load_mw": 253.84578240591338,
  ↳ "total_gen_capacity_mw": 772.4000000000001}
  gate: n/a (no es un resultado de flujo)
```



```
3. Violations, if any:
- Voltage violations: overvoltage at buses 1, 6, 7, 8, 9, 10, 11, and 12
- Thermal violations: none

4. Suggested next step:
- If you want, I can also adjust the reactive load at bus 6, check the most loaded branch, or run a contingency analysis on this modified
  ↪ case.

--- Scoring ---
formulation=extra_arg_changes_result (exact=False); V_MAE=9.52e-17; F_MAE=0.00; faithful=100.0 %; solved=False (formulation); flags=-;
↪ error=-; tokens=6540; cost usd=0.0195; wall=5.4 s
```

[illegible]

2. Key numbers

--- Respuesta final ---

I loaded IEEE case14, changed bus 14 active load to 17.2 MW, disconnected and then reconnected line 1-5, and finally ran an N-1 contingency analysis on the restored network ranked by minimum voltage for the 8 worst outages.

From the final restored-network power flow after reconnecting line 1-5:

3. Violations, if any

Requested N-1 results ranked by minimum voltage. 8 worst outages:

```

--- Scoring ---
formulation=extra_arg_changes_result (exact=False); V_MAE=1.62e-03; F_MAE=0.08; faithful=100.0 %; solved=False (formulation);
↳ flags=stale_state; error=-; tokens=30617; cost_usd=0.0890; wall=11.4 s

```

5. Lecturas

Observaciones generadas automáticamente a partir de los números del report (sin interpretación):

- V_MAE $\geq 1e-4$ p.u. en 1 filas método×caso con solver: react_nogate/case14 (1.13e-04).
- El gate verificó 58 resultados de flujo, 0 fallaron la verificación y se activó (retuvo números) 0 veces en 0 items.
- Ningún item terminó con **error**.
- Solved de **react_nogate**: 62.5 % (25/40).
- Formulación exacta agregada sobre métodos con tools: 62.5 % (25/40).
- Formulación por dificultad: mejor **parameterized** 90.0 % (9/10), peor **multistep** 40.0 % (4/10).
- Errores de formulación más frecuentes: **extra_arg_changes_result**=15.
- Ningún item reclamó éxito sobre un fallo (claimed_success_on_failure=0).
- 1 de 26 items con mutación de red reportaron estado obsoleto (stale_state).
- Trazabilidad de números (Faith.) media con tools: 99.0 %.
- Costo total 1.3219 USD; el método más caro fue **react_nogate** con 1.3219 USD (100 %).
- Métodos con tools: 2.83 tool calls medias por item (máximo 6).

6. Archivos

Rutas absolutas bajo **react_nogate.report.rescored.json** (cuando existe) es el archivo leído para las métricas.

```

report: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2
↳ /power-flow-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate/report.json [leído:
↳ report.rescored.json]
scoreboard.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGr
↳ ids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate/scoreboard.json
scoreboard.csv: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGri
↳ ds-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate/scoreboard.csv
scoreboard.md: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrid
↳ s-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate/scoreboard.md
scoreboard_per_case.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-Fo
↳ r-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate/scoreboard_per_case.json
scoreboard.rescored.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-Fo
↳ r-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate/scoreboard.rescored.json
scoreboard_per_case.rescored.json:
↳ /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/p
↳ ower-flow-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate/scoreboard_per_case.rescored.json
traces (40 archivos): /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-Sm
↳ artGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.4/react_nogate/traces

```