

Informe de experimento: llm_only_structured

Generado el 2026-09-18 21:57 por benchmarks/experiment_report.py a partir de 1 report(s) del directorio llm_only_structured (ruta completa en la sección 1). Prosa en español; identificadores (métodos, métricas, campos) en inglés tal como aparecen en los datos.

1. Qué se corrió

Directorio analizado:

```
/Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-f  
↳ low-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured
```

- Reports leídos: 1 (report.rescored.json usado en 0; el resto report.json)
- Modelos: openrouter:openai/gpt-5.6-sol
- Métodos: llm_only:structured
- Casos: case14
- Requests: generadas, N=40 por caso y seed, difficulties=todas (1 report)
- Items por dificultad: plain=10, parameterized=10, multistep=10, ambiguous=10
- runs por item: 1; k (perturbación $\pm 10\% \cdot k$): 1; seeds: [0]; max_rounds: 8; temperature: 0.0; timeout_s: 90.0
- Fecha de la corrida (mtime de report.json): 2026-09-18 00:26
- Costo total: 3.4714 USD (40 items; costo medio 0.08678 USD/item)
- Items totales: 40; ok=38; con error=2; tokens totales=410832
- Solved global: 52.5 % (21/40)

Errores por tipo:

Tipo	Items	Métodos afectados
ValueError: no_json_object_found	2	llm_only:structured (2)

2. Prompts usados

Los prompts se reconstruyen offline con el mismo código del runner (llm.prompt_variants.build_messages sobre la red perturbada con el seed del item). Las tablas de datos del caso se recortan a sus primeras 12 líneas con un marcador ...; el número de caracteres indicado corresponde al prompt completo. **Esta reconstrucción es ilustrativa, no histórica:** usa el código de llm/prompts.py de HOY, así que si el texto del prompt cambió después de que esta corrida se generó, lo que se ve aquí no es lo que el modelo recibió. El registro histórico real es el hash por fila (system_prompt_hash, ver sección 1 / benchmarks/experiment_report.py::section_what_ran), fijado en el momento de la corrida y nunca recalculado.

Método llm_only:structured

System prompt (reconstrucción con el código actual, no necesariamente histórica) —439 caracteres; strategy=structured, forced=False, sin herramientas

You are a power system analysis expert. You need to calculate AC power flow results based on test system data provided by the user.

Important Constraints:

- You must strictly output JSON (no extra text, no Markdown blocks).
- Do not output NaN/Infinity; all values must be finite real numbers.
- If you cannot complete the calculation, set `converged` to false and output the structure you can provide (an empty array is acceptable).

User prompt (primer item) —5127 caracteres; case=case14, seed=1911784258, k=1, request_id=case14-ambiguous-003-s0

System base: 100 MVA. Every per-unit quantity below (r_pu, x_pu, b_pu) is defined on this base. Line and transformer impedances (r_pu, x_pu, b_pu) are already in per unit on this base, not ohms per km; do not convert them further. Branch thermal ratings are not defined for this case, so branch loading is undefined: report loading_percent as 0 for every branch.

You are a power systems expert. Based on the following IEEE case14 test system data, calculate the AC power flow results.

System Data (from pandapower network tables)

Node Data (Bus Table: net.bus)

name	type	zone	in_service
------	------	------	------------

```

0   1   b  1.0      True
1   2   b  1.0      True
2   3   b  1.0      True
3   4   b  1.0      True
4   5   b  1.0      True
5   6   b  1.0      True
6   7   b  1.0      True
7   8   b  1.0      True
8   9   b  1.0      True
9  10   b  1.0      True
10 11   b  1.0      True
... (3 líneas omitidas de 15)

### Load Data (Load Table: net.load)

   bus      p_mw      q_mvar  in_service
0    2  21.473798  12.567615      True
1    3  85.726702  17.290948      True
2    4  45.568126  -3.717902      True
3    5   6.887322   1.449962      True
4    6  11.740497   7.861940      True
5    9  32.229269  18.135792      True
6   10   9.714580   6.260507      True
7   11   3.424253   1.761044      True
8   12   6.539657   1.715320      True
9   13  14.757610   6.340306      True
10  14  15.783969   5.296634      True

### Generator Data (Generator Table: net.gen)

   bus      p_mw  vm_pu  min_p_mw  max_p_mw  min_q_mvar  max_q_mvar  in_service
0    2  41.63323  1.045    0.0    140.0    -40.0     50.0      True
1    3   0.00000  1.010    0.0    100.0     0.0     40.0      True
2    6   0.00000  1.070    0.0    100.0    -6.0     24.0      True
3    8   0.00000  1.090    0.0    100.0    -6.0     24.0      True

### Balanced Node/External Grid (External Grid Table: net.ext_grid)

   bus  vm_pu  va_degree  in_service
0    1   1.06      0.0      True

### Line Data (Line Table: net.line)

   from_bus  to_bus      r_pu      x_pu      b_pu  parallel  in_service
0          1      2  0.01938  0.05917  0.0528      1      True
1          1      5  0.05403  0.22304  0.0492      1      True
2          2      3  0.04699  0.19797  0.0438      1      True
3          2      4  0.05811  0.17632  0.0340      1      True
4          2      5  0.05695  0.17388  0.0346      1      True
5          3      4  0.06701  0.17103  0.0128      1      True
6          4      5  0.01335  0.04211  0.0000      1      True
7          6     11  0.09498  0.19890  0.0000      1      True
8          6     12  0.12291  0.25581  0.0000      1      True
9          6     13  0.06615  0.13027  0.0000      1      True
10         9     10  0.03181  0.08450  0.0000      1      True
... (4 líneas omitidas de 16)

### Transformer Data (Transformer Table: net.trafo)

   hv_bus  lv_bus  r_pu      x_pu  shift_degree  tap_side  tap_neutral  tap_min  tap_max  tap_step_percent  in_service
0         4      7   0.0  0.20912      0.0      hv      0.0      NaN      NaN      2.2      True
1         4      9   0.0  0.55618      0.0      hv      0.0      NaN      NaN      3.1      True
2         5      6   0.0  0.25202      0.0      hv      0.0      NaN      NaN      6.8      True
3         7      8   0.0  0.17615      0.0     None      NaN      NaN      NaN      NaN      True
4         7      9   0.0  0.11001      0.0     None      NaN      NaN      NaN      NaN      True

## Task
Load case14 and disconnect the line between bus ten and bus eleven.

## Output Requirements
Please calculate and return the following results (JSON format):

1) Voltage magnitude (p.u.) and phase angle (degrees) for each node

2) Active power (MW) and load factor (%) at the beginning of each branch

- For lines: `line_id` uses the row index of `net.line`
- For transformers: `line_id` uses the row index of 100000 + `net.trafo`

3) Total generation (MW), total load (MW), total losses (MW)

4) Are there any voltage overruns (<0.95 or >1.05 p.u.) or line overruns (>100%)?

Please strictly follow the following JSON schema output (all fields are complete and of correct type):

{

```

```

"converged": true/false,

"bus_voltages": [{"bus_id": 1, "vm_pu": 1.0, "va_deg": 0.0}, ...],

"line_flows": [{"line_id": 0, "p_from_mw": 0.0, "loading_percent": 0.0}, ...],

"total_generation_mw": 0.0,

"total_load_mw": 0.0,
"total_loss_mw": 0.0
}

```

[Important] bus_id must use the `name` column of net.bus (the usual IEEE/MATPOWER 1..N numbering), not the row index of net.bus.

3. Resultados agregados

Columnas del protocolo (medias por método $\times$ caso, del `scoreboard_per_case`), en los 4 grupos de `metricas_pfagent_definicion`
utilidad de tarea Form. (formulación exacta de las tool calls), V_MAE (p.u., solo sobre peticiones con formulación exacta –toda fila con herramientas que llega al solver con la formulación correcta da exactamente cero, ver benchmarks/scoring.py) y F_MAE (MW) sobre los items con resultado, Solved (respondió correctamente de extremo a extremo); **corrección solver-grounded** Solver status (convergencia reportada = convergencia real), B_mean (residual medio de KCL de los flujos reportados, MW); **fidelidad** Faith. (por respuesta, no por número: fracción de respuestas donde todo número es trazable a una salida de tool Y viene del solve posterior al último cambio de red) y SFR (fallos declarados con seguridad); **costo** Calls (tool calls medias) y Tok. (tokens medios). Fuera de los 4 grupos, solo en este reporte (no en las tablas del paper): Claim (éxito reclamado sobre un fallo), Escalated y Wrong (silent). Escalated y Wrong (silent) junto con solved_automously_rate (no la columna Solved de arriba, que puede solaparse con Escalated –una abstención de verificación puede caer sobre un item cuyo cálculo de fondo sí era correcto) suman 100 %: dónde termina cada petición –resuelta sola, entregada a una persona, o mal contestada sin aviso; solo cuenta como Escalated una arquitectura con mecanismo de traspaso real, ver benchmarks.scoring.escalation_check) y \$ (costo total USD). Porcentajes en %.

Por método $\times$ caso

Method	Case	N	Form.	V_MAE	F_MAE	Solved	Solver status	B_mean	Faith.	SFR	Calls	Tok.	Claim	Escalated	Wrong (silent)	\$
llm_only:structured	case14	40	–	1.70e-03	1.42	52.5 (21/40)	92.1 (35/38)	3.78e-01	5.0 (2/40)	–	n/a	10271	–	–	–	3.4714

Formulación exacta por dificultad (items con etapa de tools; n/a = sin tools)

Method	plain	parameterized	multistep	ambiguous
llm_only:structured	n/a	n/a	n/a	n/a

Solved por dificultad (%, items resueltos / items)

Method	plain	parameterized	multistep	ambiguous
llm_only:structured	70.0 (7/10)	40.0 (4/10)	40.0 (4/10)	60.0 (6/10)

Tipos de error de formulación (conteo de items)

Method	unparsed
llm_only:structured	2

Errores de ejecución por método (conteo de items con error)

Method	ValueError: no_json_object_found
llm_only:structured	2

4. Trazas de ejemplo

Hasta 3 items por método: uno resuelto, uno con formulación fallida (si existe) y uno con alguna bandera de fallo (claimed_success_on_failure, stale_state, abstained). Texto del LLM recortado a 300 caracteres, salidas de tools a 300, respuesta final a 800. Se lee la traza completa de **traces/** cuando existe.

Método llm_only:structured

Ejemplo: resuelto (solved=True)

```
request (case14-ambiguous-003-s0, case14, difficulty=ambiguous, seed=1911784258): Load case14 and disconnect the line between bus ten and
↳ bus eleven.
intended_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 10, "to_bus": 11})
executed_calls: (sin etapa de tools)
fuente de la traza: archivo de traza completo
(sin rondas de herramientas: una sola llamada al LLM)
--- Respuesta final ---
{"converged":true,"bus_voltages":[{"bus_id":1,"vm_pu":1.06,"va_deg":0.0}, {"bus_id":2,"vm_pu":1.045,"va_deg":-4.91}, {"bus_id":3,"vm_pu":1.01
↳ ,"va_deg":-12.53}, {"bus_id":4,"vm_pu":1.0165,"va_deg":-10.42}, {"bus_id":5,"vm_pu":1.0186,"va_deg":-8.91}, {"bus_id":6,"vm_pu":1.07,"va_d
↳ eg":-14.19}, {"bus_id":7,"vm_pu":1.0595,"va_deg":-13.72}, {"bus_id":8,"vm_pu":1.09,"va_deg":-13.72}, {"bus_id":9,"vm_pu":1.0508,"va_deg":-
↳ 15.53}, {"bus_id":10,"vm_pu":1.0446,"va_deg":-15.91}, {"bus_id":11,"vm_pu":1.063,"va_deg":-14.32}, {"bus_id":12,"vm_pu":1.054,"va_deg":-15
↳ .13}, {"bus_id":13,"vm_pu":1.048,"va_deg":-15.37}, {"bus_id":14,"vm_pu":1.031,"va_deg":-16.53}], "line_flows": [{"line_id":0, "p_from_mw":15
↳ 1.5, "loading_percent":0.0}, {"line_id":1, "p_from_mw":74.4, "loading_percent":0.0}, {"line_id":2, "p_from_mw":69.5, "loading_pe ...[1031 chars
↳ más]
--- Scoring ---
formulation=n/a (exact=None); V_MAE=9.94e-04; F_MAE=0.32; faithful=0.0 %; solved=True (numeric_ok); flags=-; error=-; tokens=10836;
↳ cost_usd=0.0923; wall=173.1 s
```

Ejemplo: no resuelto

```
request (case14-ambiguous-007-s0, case14, difficulty=ambiguous, seed=2073320062): Load the 14-bus test case (case14) and disconnect the
↳ line between bus 6 and bus 13 (1-based).
intended_calls: load_case({"case_name": "case14"}) -> disconnect_line({"from_bus": 6, "to_bus": 13})
executed_calls: (sin etapa de tools)
fuente de la traza: archivo de traza completo
(sin rondas de herramientas: una sola llamada al LLM)
--- Respuesta final ---
{"converged":true,"bus_voltages":[{"bus_id":1,"vm_pu":1.06,"va_deg":0.0}, {"bus_id":2,"vm_pu":1.045,"va_deg":-5.05}, {"bus_id":3,"vm_pu":1.01
↳ ,"va_deg":-12.94}, {"bus_id":4,"vm_pu":1.013,"va_deg":-10.47}, {"bus_id":5,"vm_pu":1.018,"va_deg":-8.89}, {"bus_id":6,"vm_pu":1.07,"va_deg
↳ ", "-14.02}, {"bus_id":7,"vm_pu":1.059,"va_deg":-13.75}, {"bus_id":8,"vm_pu":1.09,"va_deg":-13.75}, {"bus_id":9,"vm_pu":1.049,"va_deg":-15.4
↳ 3}, {"bus_id":10,"vm_pu":1.045,"va_deg":-15.47}, {"bus_id":11,"vm_pu":1.053,"va_deg":-15.07}, {"bus_id":12,"vm_pu":1.046,"va_deg":-16.28},
↳ {"bus_id":13,"vm_pu":1.025,"va_deg":-17.62}, {"bus_id":14,"vm_pu":1.022,"va_deg":-17.31}], "line_flows": [{"line_id":0, "p_from_mw":159.8,
↳ loading_percent":0.0}, {"line_id":1, "p_from_mw":77.196895, "loading_percent":0.0}, {"line_id":2, "p_from_mw":74.8, "loading_pe ...[1026 chars
↳ más]
--- Scoring ---
formulation=n/a (exact=None); V_MAE=4.30e-03; F_MAE=0.56; faithful=0.0 %; solved=False (voltage_error); flags=-; error=-; tokens=13669;
↳ cost_usd=0.1206; wall=225.7 s
```

Ejemplo: primer item

```
request (case14-ambiguous-011-s0, case14, difficulty=ambiguous, seed=1971893210): Load case14 and set the active load at bus 6 to 14,700 kw.
intended_calls: load_case({"case_name": "case14"}) -> modify_load({"bus_id": 6, "p_mw": 14.7})
executed_calls: (sin etapa de tools)
fuente de la traza: archivo de traza completo
(sin rondas de herramientas: una sola llamada al LLM)
--- Respuesta final ---
{"converged":true,"bus_voltages":[{"bus_id":1,"vm_pu":1.06,"va_deg":0.0}, {"bus_id":2,"vm_pu":1.045,"va_deg":-5.237}, {"bus_id":3,"vm_pu":1.0
↳ 1,"va_deg":-13.399}, {"bus_id":4,"vm_pu":1.0169,"va_deg":-10.782}, {"bus_id":5,"vm_pu":1.0192,"va_deg":-9.206}, {"bus_id":6,"vm_pu":1.07,"
↳ va_deg":-15.118}, {"bus_id":7,"vm_pu":1.0604,"va_deg":-13.907}, {"bus_id":8,"vm_pu":1.09,"va_deg":-13.907}, {"bus_id":9,"vm_pu":1.0558,"va
↳ _deg":-15.524}, {"bus_id":10,"vm_pu":1.051,"va_deg":-15.711}, {"bus_id":11,"vm_pu":1.0565,"va_deg":-15.55}, {"bus_id":12,"vm_pu":1.0549,"v
↳ a_deg":-16.019}, {"bus_id":13,"vm_pu":1.0498,"va_deg":-16.094}, {"bus_id":14,"vm_pu":1.0349,"va_deg":-16.809}], "line_flows": [{"line_id":0
↳ , "p_from_mw":164.423, "loading_percent":0.0}, {"line_id":1, "p_from_mw":78.93935, "loading_percent":0.0}, {"line_id":2, "p_from ...[1086 chars
↳ más]
--- Scoring ---
formulation=n/a (exact=None); V_MAE=5.61e-04; F_MAE=0.08; faithful=0.0 %; solved=True (numeric_ok); flags=-; error=-; tokens=10881;
↳ cost_usd=0.0927; wall=144.8 s
```

5. Lecturas

Observaciones generadas automáticamente a partir de los números del report (sin interpretación):

- LLM-only: V_MAE entre 1.70e-03 (llm_only:structured/case14) y 1.70e-03 (llm_only:structured/case14) p.u. sobre los items que devolvieron números.
- 0.0 % (0/40) de abstención en LLM-only (respuesta con converged=false o arrays vacíos).
- En LLM-only, 3 items no resueltos por convergence_mismatch y 14 por voltage_error.
- 2 items con error ValueError: no_json_object_found.
- Solved de llm_only:structured: 52.5 % (21/40).
- Ningún item reclamó éxito sobre un fallo (claimed_success_on_failure=0).

- Trazabilidad de números (Faith.) media en LLM-only: 2.1 % (sin tools, todo número es no trazable salvo los copiados de la request).
- Costo total 3.4714 USD; el método más caro fue `llm_only:structured` con 3.4714 USD (100 %).

6. Archivos

Rutas absolutas bajo `llm_only_structured.report.rescored.json` (cuando existe) es el archivo leído para las métricas.

```
report: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2
↳ /power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/report.json
scoreboard.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/scoreboard.json
↳ ids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/scoreboard.json
scoreboard.csv: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/scoreboard.csv
↳ ds-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/scoreboard.csv
scoreboard.md: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/scoreboard.md
↳ s-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/scoreboard.md
scoreboard_per_case.json: /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/scoreboard_per_case.json
↳ r-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/scoreboard_per_case.json
traces (40 archivos): /Users/lzanda/Documents/REVIEW-TUTORIAL-LLMS-AND-AGENTIC-FOR-SMART-GRIDS/03-codigo-casos-estudio/LLMs-Agents-For-SmartGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/traces
↳ artGrids-Code-v2/power-flow-agent/benchmarks/results_validation_n40/gpt-5.6-sol/llm_only_structured/traces
```